

Procesamiento de Lenguaje Natural (NLP)

Clase 2: Vectorización de Texto

Prof. D.Sc. BARSEKH-ONJI Aboud

Faculty of Engineering
Universidad Anáhuac México Sur

23 de octubre de 2025

Agenda de la Clase

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

Agenda

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

¿Dónde nos quedamos?

Resumen de la Clase 1

Aprendimos a tomar texto "sucio" y, mediante el **preprocesamiento**, lo convertimos en una lista de tokens limpios y estandarizados.

Texto Crudo

"Los alumnos estan aprendiendo..." ↓ *Limpieza* ↓ **Tokens Procesados**

`'alumn', 'aprend', 'procesamiento', ...`

El Problema Actual

Nuestros tokens son limpios, ¡pero siguen siendo palabras! Los modelos de Machine Learning no entienden palabras, solo entienden **números**.

Objetivo de Hoy: La Vectorización

El proceso de convertir texto en una representación numérica (vectores o matrices) se llama **vectorización** o *feature extraction*.

Tokens Limpios $\xrightarrow{\text{Vectorización}}$ Matriz Numérica

Hoy aprenderemos dos técnicas fundamentales para lograr esto: **Bag-of-Words** y **TF-IDF**.

Agenda

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

Bag-of-Words (BoW): Una Idea Sencilla

Analogía

Imagina que tomas todas las palabras de un documento, las metes en una bolsa, las revuelves y luego cuentas cuántas veces aparece cada una. **El orden no importa, solo la frecuencia.**

El proceso tiene dos pasos clave:

1. **Crear un Vocabulario:** Construir una lista de todas las palabras únicas que aparecen en *todos* nuestros documentos.

Bag-of-Words (BoW): Una Idea Sencilla

Analogía

Imagina que tomas todas las palabras de un documento, las metes en una bolsa, las revuelves y luego cuentas cuántas veces aparece cada una. **El orden no importa, solo la frecuencia.**

El proceso tiene dos pasos clave:

1. **Crear un Vocabulario:** Construir una lista de todas las palabras únicas que aparecen en *todos* nuestros documentos.
2. **Contar Frecuencias:** Para cada documento, contar cuántas veces aparece cada palabra del vocabulario.

Bag-of-Words: Ejemplo Visual

Supongamos que tenemos dos documentos (después de preprocesar):

- **Doc 1:** "gato persigue raton"
- **Doc 2:** "perro persigue gato"

Bag-of-Words: Ejemplo Visual

Supongamos que tenemos dos documentos (después de preprocesar):

- **Doc 1:** "gato persigue raton"
- **Doc 2:** "perro persigue gato"

1. **Vocabulario único:** {gato, persigue, raton, perro}

Bag-of-Words: Ejemplo Visual

Supongamos que tenemos dos documentos (después de preprocesar):

- **Doc 1:** "gato persigue raton"
- **Doc 2:** "perro persigue gato"

1. **Vocabulario único:** {gato, persigue, raton, perro}
2. **Contar frecuencias para crear vectores:**

	gato	persigue	raton	perro
Doc 1	1	1	1	0
Doc 2	1	1	0	1

¡Hemos convertido el texto en una matriz numérica! Cada fila es un documento.

Limitaciones del Modelo BoW

El Problema: Todas las palabras pesan lo mismo

En el modelo BoW simple, la palabra "excelente" tiene la misma importancia que la palabra "producto" si ambas aparecen una vez.

Consideremos estas frases:

- "El producto es **excelente**."
- "El producto es **terrible**."

Intuitivamente, sabemos que "excelente" y "terrible" son más importantes para determinar la opinión que "producto".

¿Cómo podemos dar más peso a las palabras más significativas?

La respuesta es **TF-IDF**.

Agenda

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

TF-IDF: Dando Peso a lo Importante

Definición

TF-IDF significa *Term Frequency - Inverse Document Frequency*. Es una puntuación numérica que refleja qué tan importante es una palabra para un documento dentro de una colección de documentos.

La puntuación se compone de dos partes:

1. TF (Frecuencia del Término):

- ¿Qué tan seguido aparece la palabra en **un documento**?
- Si una palabra aparece mucho, es importante *para ese documento*.

2. IDF (Frecuencia Inversa de Documento):

- ¿Qué tan rara es la palabra en **toda la colección**?
- Si una palabra aparece en muchos documentos (como "producto"), es menos informativa y recibe un peso bajo.

$$\text{Puntuación TF-IDF} = \text{TF} \times \text{IDF}$$

La Puntuación TF-IDF es alta cuando...

Una palabra aparece **muchas veces** dentro de un documento (*TF alto*), pero **pocas veces** en el resto de los documentos de la colección (*IDF alto*).

- Esto resalta las palabras que son **distintivas y características** de un documento en particular.
- Por ejemplo, en un artículo sobre "Inteligencia Artificial", la palabra "neuronal" tendrá un TF-IDF alto. En un conjunto de noticias, la palabra "el" tendrá un TF-IDF muy bajo.

Agenda

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

Creando una Matriz TF-IDF en MATLAB

Objetivo

Convertir un conjunto de comentarios de texto en una matriz numérica TF-IDF, lista para ser usada en un modelo de IA.

Creando una Matriz TF-IDF en MATLAB

```
1 % 1. Datos de ejemplo: 3 comentarios de un producto
2 textos = [
3     "La bateria dura mucho, excelente producto.",
4     "La pantalla es grande y la camara es buena.",
5     "La bateria no dura nada, un producto terrible."
6 ];
7
8 % 2. Preprocesamos los textos (usando los pasos de la Clase 1)
9 documentos = tokenizedDocument(lower(textos));
10 documentos = erasePunctuation(documentos);
11 listaStopWords = ["y", "la", "el", "es", "un", "una"];
12 documentos = removeWords(documentos, listaStopWords);
13 documentos = normalizeWords(documentos, 'Style', 'stem');
14
15 % 3. Crear el modelo de Bag-of-Words
16 bolsa = bagOfWords(documentos);
17
18 % 4. Convertir los documentos a una matriz TF-IDF
19 matrizTfidf = tfidf(bolsa);
```

Paso 1: El Vocabulario Creado

La función 'bagOfWords' crea el vocabulario automáticamente.

```
1 >> disp(bolsa.Vocabulary)
2
3 'bateri'      'buen'      'camar'      'dur'      'excelent' ...
4 'grand'      'much'      'nad'        'pantall'  'product'   'terribl'
```

Paso 2: La Matriz Numérica Final

La función 'tfidf' genera la matriz, donde cada fila es un comentario y cada columna es una palabra del vocabulario.

```
1 >> disp(full(matrizTfidf))
2
3 %          bateri    buen    camar    dur    ...
4 ans =
5    0.2588         0         0    0.2588    ... (Comentario 1)
6         0    0.3536  0.3536         0    ... (Comentario 2)
7    0.2182         0         0    0.2182    ... (Comentario 3)
```

Interpretando los Números de la Matriz

¿Qué significa cada número?

Cada valor en la matriz representa la **puntuación TF-IDF** de una palabra (columna) para un documento específico (fila). Un número más alto significa que la palabra es más importante o distintiva para ese documento.

Vamos a analizar un ejemplo:

- La palabra 'bateri' tiene un valor alto en la Fila 1 y Fila 3, pero **cero** en la Fila 2.
 - **¿Por qué?** Porque la palabra "batería" solo aparece en el primer y tercer comentario. El cero indica su ausencia en el segundo.
- La palabra 'excellent' (en la Fila 1) probablemente tendrá una puntuación TF-IDF más alta que 'product'.
 - **¿Por qué?** Aunque ambas aparecen una vez (TF similar), 'product' aparece en dos documentos, haciéndola menos única (IDF más bajo). En cambio, 'excellent' es una palabra muy distintiva de ese primer comentario.

La Gran Idea

No solo contamos palabras; hemos calculado su **relevancia ponderada**. Esto es lo que permite a un modelo de IA enfocarse en las palabras que realmente definen el significado de un texto.

Agenda

1. Repaso y El Siguiente Paso
2. Modelo Bag-of-Words (Bolsa de Palabras)
3. Ponderación TF-IDF
4. Ejemplo Práctico en MATLAB
5. Conclusiones y Próximos Pasos

- **Vectorizar es Esencial:** Es el proceso de convertir palabras en números, un paso obligatorio para aplicar Machine Learning al texto.
- **Bag-of-Words (BoW):** Es un modelo simple y efectivo que representa documentos basándose en la frecuencia de las palabras.
- **TF-IDF:** Es una técnica de ponderación que mejora a BoW al dar más importancia a las palabras que son realmente distintivas de un documento.
- **Logro de Hoy:** ¡Ya sabemos cómo transformar texto crudo en una **matriz numérica significativa**!

La Próxima Frontera: Aplicaciones Reales

Ahora que nuestros datos de texto están en un formato que una máquina puede "entender", podemos empezar a hacer tareas útiles con ellos.

En la próxima etapa, se dará un primer paso en las aplicaciones de NLP: realizando un **Análisis de Sentimientos** para clasificar automáticamente si un comentario es positivo, negativo o neutral.