

Principios de Machine Learning

Materia: Fundamentos de Inteligencia Artificial

Prof. D.Sc. BARSEKH-ONJI Aboud

Facultad de Ingeniería
Universidad Anáhuac México

7 de diciembre de 2025

Agenda

1. Introducción al Aprendizaje Automático
2. Aprendizaje Supervisado
3. Aprendizaje No Supervisado
4. Aprendizaje por Refuerzo
5. Tratamiento de Datos
 - 5.1 Datos de Entrenamiento, Validación y Prueba
 - 5.2 Validación Cruzada

¿Qué es el Aprendizaje Automático (Machine Learning)?

Definición

Es una rama de la Inteligencia Artificial que se enfoca en el desarrollo de sistemas capaces de **aprender y mejorar a partir de la experiencia**, sin ser programados explícitamente para cada tarea.

El Proceso de Aprendizaje

En lugar de seguir instrucciones fijas, los algoritmos de ML construyen un **modelo matemático** basado en **datos de entrenamiento** para realizar predicciones o tomar decisiones.

El Objetivo Clave: Generalización

Generalización

Se dice que un modelo **generaliza** bien si, después de aprender de un conjunto de datos, es capaz de realizar **predicciones correctas sobre datos nuevos y no vistos**.

La Ciencia del Aprendizaje Automático

El objetivo fundamental no es crear un modelo que memorice los datos de entrenamiento, sino aprender un modelo que **generalice bien**.

Principales Categorías del Aprendizaje Automático

- **Aprendizaje Supervisado:**

- El modelo aprende de datos **etiquetados** (cada entrada tiene una salida correcta conocida).
- **Objetivo:** Predecir una salida.

Principales Categorías del Aprendizaje Automático

- **Aprendizaje Supervisado:**

- El modelo aprende de datos **etiquetados** (cada entrada tiene una salida correcta conocida).
- **Objetivo:** Predecir una salida.

- **Aprendizaje No Supervisado:**

- El modelo aprende de datos **sin etiquetar**.
- **Objetivo:** Encontrar patrones o estructuras ocultas en los datos.

Principales Categorías del Aprendizaje Automático

- **Aprendizaje Supervisado:**

- El modelo aprende de datos **etiquetados** (cada entrada tiene una salida correcta conocida).
- **Objetivo:** Predecir una salida.

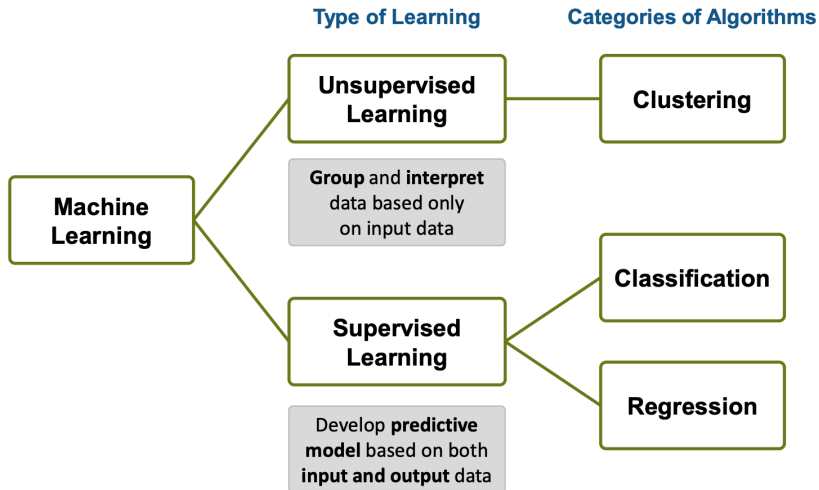
- **Aprendizaje No Supervisado:**

- El modelo aprende de datos **sin etiquetar**.
- **Objetivo:** Encontrar patrones o estructuras ocultas en los datos.

- **Aprendizaje por Refuerzo:**

- Un **agente** aprende interactuando con un **entorno**.
- **Objetivo:** Aprender una estrategia para maximizar una **recompensa** a largo plazo.

Principales Categorías del Aprendizaje Automático



Agenda

1. Introducción al Aprendizaje Automático
2. Aprendizaje Supervisado
3. Aprendizaje No Supervisado
4. Aprendizaje por Refuerzo
5. Tratamiento de Datos
 - 5.1 Datos de Entrenamiento, Validación y Prueba
 - 5.2 Validación Cruzada

Aprendizaje Supervisado: Aprender de Ejemplos Etiquetados

Definición

En el aprendizaje supervisado, el algoritmo aprende a partir de un conjunto de datos de entrenamiento que consiste en pares de entrada-salida. Cada ejemplo de entrenamiento (\mathbf{x}_i, y_i) incluye un vector de características de entrada y una **etiqueta de salida o valor objetivo conocido**.

Objetivo

Aprender una función de mapeo $f : X \rightarrow Y$ tal que $f(\mathbf{x}) \approx y$. Una vez entrenado, el modelo puede **predecir la salida** para nuevas entradas para las cuales la salida es desconocida.

Tareas del Aprendizaje Supervisado: Regresión vs. Clasificación

Regresión

- La variable de salida y es un valor **continuo** o **cuantitativo**.
- El objetivo es predecir un valor numérico.
- **Ejemplos:**
 - Predecir el precio de una casa.
 - Estimar la temperatura de mañana.

Clasificación

- La variable de salida y es una etiqueta **categorica** o **cualitativa**.
- El objetivo es asignar una etiqueta de clase.
- **Ejemplos:**
 - Clasificar un correo como 'spam' o 'no spam'.
 - Identificar si una imagen contiene un gato, un perro o un pájaro.

Agenda

1. Introducción al Aprendizaje Automático
2. Aprendizaje Supervisado
3. Aprendizaje No Supervisado
4. Aprendizaje por Refuerzo
5. Tratamiento de Datos
 - 5.1 Datos de Entrenamiento, Validación y Prueba
 - 5.2 Validación Cruzada

Encontrando Patrones en Datos sin Etiquetar

Definición

A diferencia del aprendizaje supervisado, en el aprendizaje no supervisado el algoritmo recibe datos de entrada \mathbf{x}_i **sin ninguna etiqueta de salida** explícita y_i .

Objetivo

Descubrir patrones, estructura o conocimiento inherente directamente de los datos no etiquetados. El modelo debe encontrar por sí mismo las relaciones en los datos.

- **Agrupamiento (Clustering):**
 - Consiste en agrupar los datos en clústeres, de modo que los puntos dentro de un mismo clúster sean muy similares entre sí.
 - *Ejemplo:* Segmentar clientes en grupos con comportamientos de compra parecidos.

Tareas Comunes del Aprendizaje No Supervisado

- **Agrupamiento (Clustering):**

- Consiste en agrupar los datos en clústeres, de modo que los puntos dentro de un mismo clúster sean muy similares entre sí.
- *Ejemplo:* Segmentar clientes en grupos con comportamientos de compra parecidos.

- **Reducción de Dimensionalidad:**

- Busca reducir el número de variables (características) de un conjunto de datos, conservando la mayor cantidad de información relevante posible.
- *Ejemplo:* Simplificar un modelo o facilitar la visualización de datos complejos.

Tareas Comunes del Aprendizaje No Supervisado

- **Agrupamiento (Clustering):**

- Consiste en agrupar los datos en clústeres, de modo que los puntos dentro de un mismo clúster sean muy similares entre sí.
- *Ejemplo:* Segmentar clientes en grupos con comportamientos de compra parecidos.

- **Reducción de Dimensionalidad:**

- Busca reducir el número de variables (características) de un conjunto de datos, conservando la mayor cantidad de información relevante posible.
- *Ejemplo:* Simplificar un modelo o facilitar la visualización de datos complejos.

- **Aprendizaje de Reglas de Asociación:**

- Descubre relaciones interesantes entre variables en grandes conjuntos de datos.
- *Ejemplo:* "Los clientes que compran pañales también tienden a comprar cerveza".

Agenda

1. Introducción al Aprendizaje Automático
2. Aprendizaje Supervisado
3. Aprendizaje No Supervisado
4. Aprendizaje por Refuerzo
5. Tratamiento de Datos
 - 5.1 Datos de Entrenamiento, Validación y Prueba
 - 5.2 Validación Cruzada

Aprender a través de la Interacción

Definición

Es un paradigma donde un **agente** aprende a tomar una secuencia de **acciones** en un **entorno** para maximizar una noción de **recompensa** acumulada a lo largo del tiempo.

Aprendizaje por Prueba y Error

El agente no recibe ejemplos de "entrada-salida correcta". En su lugar, aprende a través de la interacción y la retroalimentación (recompensas o castigos) de sus acciones para desarrollar una estrategia ganadora.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.
- **Entorno:** El mundo (real o simulado) con el que interactúa el agente.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.
- **Entorno:** El mundo (real o simulado) con el que interactúa el agente.
- **Estado (s):** Una descripción de la situación actual del entorno.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.
- **Entorno:** El mundo (real o simulado) con el que interactúa el agente.
- **Estado (s):** Una descripción de la situación actual del entorno.
- **Acción (a):** Una elección que el agente puede tomar en un estado dado.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.
- **Entorno:** El mundo (real o simulado) con el que interactúa el agente.
- **Estado (s):** Una descripción de la situación actual del entorno.
- **Acción (a):** Una elección que el agente puede tomar en un estado dado.
- **Recompensa (r):** Una señal numérica que el entorno proporciona al agente después de cada acción.

Componentes Clave del Aprendizaje por Refuerzo

- **Agente:** La entidad que aprende y toma decisiones.
- **Entorno:** El mundo (real o simulado) con el que interactúa el agente.
- **Estado (s):** Una descripción de la situación actual del entorno.
- **Acción (a):** Una elección que el agente puede tomar en un estado dado.
- **Recompensa (r):** Una señal numérica que el entorno proporciona al agente después de cada acción.
- **Política (π):** La estrategia que utiliza el agente para seleccionar acciones. **El objetivo del RL es aprender una política óptima.**

El Dilema Central: Exploración vs. Explotación

Exploración

- Consiste en probar nuevas acciones para descubrir qué tan efectivas son.
- Es necesario para encontrar mejores estrategias y no quedarse atascado en una solución subóptima.
- Implica un riesgo a corto plazo con la esperanza de una mayor recompensa a largo plazo.

Explotación

- Consiste en utilizar el conocimiento actual para tomar las acciones que se sabe que son las mejores.
- Maximiza la recompensa a corto plazo basándose en la experiencia pasada.
- Si se explota demasiado pronto, el agente podría nunca descubrir acciones mucho mejores.

El Dilema Central: Exploración vs. Explotación

El Equilibrio

Un agente de RL exitoso debe encontrar un equilibrio inteligente entre explorar su entorno para adquirir nuevo conocimiento y explotar su conocimiento actual para obtener recompensas.

Agenda

1. Introducción al Aprendizaje Automático
2. Aprendizaje Supervisado
3. Aprendizaje No Supervisado
4. Aprendizaje por Refuerzo
5. Tratamiento de Datos
 - 5.1 Datos de Entrenamiento, Validación y Prueba
 - 5.2 Validación Cruzada

Tratamiento de Datos: La Base del Éxito

División de los Datos

La calidad y la gestión adecuada de los datos son fundamentales para el éxito. Un paso crítico es dividir el conjunto de datos total en tres subconjuntos independientes:

Entrenamiento, Validación y Prueba

Datos de Entrenamiento	Datos de Validación	Datos de Prueba
(p.ej., 60 %-70 %)	(p.ej., 15 %-20 %)	(p.ej., 15 %-20 %)

Definición de los Conjuntos de Datos

Datos de Entrenamiento (Training)

- Es la porción de datos que se utiliza para ^{en}señar.º ajustar los parámetros del modelo.
- El modelo aprende los patrones y relaciones subyacentes presentes en estos datos.

Datos de Validación (Validation)

- Se utiliza para el **ajuste de hiperparámetros** (e.g., el número de vecinos k en k-NN).
- Sirve para la **selección de modelos** (comparar un árbol de decisión vs. una SVM).
- Ayuda a detectar el **sobreajuste** (overfitting).

Examples

Datos de Prueba (Testing) Se mantiene completamente separado y se utiliza **una sola vez** al final del proceso para proporcionar una evaluación final e **insesgada** del rendimiento del modelo en datos del mundo real.

Técnica Robusta: Validación Cruzada (k-Fold CV)

¿Qué es la Validación Cruzada?

Es una técnica para obtener una estimación más estable del rendimiento del modelo. En lugar de una única división, los datos se dividen en k "pliegues" (folds), y el modelo se entrena y valida k veces.

Proceso de k-Fold Cross-Validation

- Dividir los datos de entrenamiento en k subconjuntos (pliegues).
- En cada una de las k iteraciones:
 - Se utiliza un pliegue diferente para la **validación**.
 - Se utilizan los $k - 1$ pliegues restantes para el **entrenamiento**.
- Se promedian los k resultados de validación para obtener la estimación final del rendimiento.

Ejemplo de Código: División de Datos

Python (Scikit-learn)

```
from  
sklearn.model_selection import train_test_split  
Dividir en 80% entrenamiento y 20% prueba  
train_test_split(X, y, test_size =  
0.2, random_state = 42)
```

MATLAB

```
cvp = cvpartition(Y, 'Holdout', 0.20);  
X_train = X(cvp.training,:); Y_train =  
Y(cvp.training); X_test = X(cvp.test,:);  
Y_test = Y(cvp.test);
```