

Sistema de Inferencia Difusa: Score de Riesgo Crediticio Simplificado

Autor: Prof. D.Sc. Aboud Barsekh-Onji **Institución:** Universidad Anáhuac México
Contexto: Material didáctico para curso de Sistemas de Inferencia Difusa

1. Descripción del Problema

Las instituciones financieras deben decidir si otorgan crédito a un solicitante, y en qué condiciones, evaluando su **riesgo** de incumplimiento. En este ejercicio simplificado, dicho riesgo se estima a partir de dos indicadores:

1. La **capacidad de pago relativa**, expresada como un ratio normalizado entre el ingreso mensual del solicitante y su nivel de deuda actual (entre más alto, mejor capacidad de pago).
2. El **historial de pago**, una calificación de 0 a 10 que resume el comportamiento pasado del solicitante (pagos puntuales, atrasos, incumplimientos previos).

El objetivo del sistema es producir un **score de riesgo crediticio** en una escala de 0 a 100, donde 0 representa riesgo nulo (cliente ideal) y 100 representa riesgo máximo (alta probabilidad de incumplimiento).

Este problema es uno de los ejemplos más citados en la literatura de lógica difusa aplicada a finanzas, porque combina **criterios cuantitativos con juicios cualitativos** que tradicionalmente formulan los analistas de crédito en lenguaje natural (“buen ingreso pero mal historial = riesgo considerable”).

2. Naturaleza de las Variables

2.1 Variables de Entrada

Variable	Rango	Naturaleza	Conjuntos difusos sugeridos
Ingreso relativo a deuda (ratio normalizado)	0 – 10	Continua, cuantitativa, derivada de datos financieros objetivos (ingreso / deuda, normalizado)	Insuficiente, Bajo, Adecuado, Alto

Variable	Rango	Naturaleza	Conjuntos difusos sugeridos
Historial de pago	0 – 10	Discreta/continua, semicuantitativa — suele construirse a partir de un score crediticio existente o de conteos de incidencias (atrasos, defaults)	Malo, Regular, Bueno, Excelente

Ambas variables provienen de **fuentes de datos verificables** (estados de cuenta, buró de crédito), pero su interpretación en términos de “riesgo” depende de criterios expertos que varían entre instituciones, regiones y contextos económicos — exactamente el tipo de conocimiento que un FIS puede encapsular.

2.2 Variable de Salida

Variable	Rango	Naturaleza	Conjuntos difusos sugeridos
Score de riesgo crediticio	0 – 100	Continua, índice compuesto utilizado para decisiones (aprobar/rechazar, definir tasa de interés, límite de crédito)	Muy Bajo, Bajo, Moderado, Alto, Muy Alto

La salida es un **índice de decisión**: no mide directamente una cantidad física, sino que sintetiza el juicio de un analista experto en una escala continua que posteriormente puede mapearse a decisiones discretas (por ejemplo, score > 70 → rechazar; score < 30 → aprobar con tasa preferencial).

3. ¿Por qué Lógica Difusa es Recomendable Aquí?

1. **El conocimiento crediticio experto es naturalmente lingüístico.** Los analistas de crédito razonan en términos como “ingreso adecuado”, “historial bueno” o “riesgo moderado”, no con umbrales numéricos rígidos. Un FIS permite capturar directamente reglas como *“Si el ingreso relativo es Bajo Y el historial es Malo, ENTONCES el riesgo es Muy Alto”*, preservando el razonamiento experto sin forzarlo a una fórmula estadística cerrada.

2. **Evita las discontinuidades artificiales de los sistemas basados en reglas rígidas (if-else).** Un sistema de scoring tradicional basado en umbrales fijos (por ejemplo, “historial < 5 → rechazar”) genera saltos abruptos: dos solicitantes con historiales de 4.9 y 5.1 recibirían decisiones opuestas, pese a ser prácticamente idénticos. La lógica difusa suaviza estas fronteras mediante funciones de membresía superpuestas, produciendo un score que varía de forma continua y más justa.
3. **Captura interacciones no-lineales entre criterios sin necesidad de un modelo estadístico complejo.** El efecto combinado de “buen ingreso + mal historial” no es simplemente la suma de ambos efectos por separado: un historial de incumplimientos reciente puede pesar mucho más que un buen ingreso actual. Las reglas difusas permiten codificar estas asimetrías directamente, sin necesidad de ajustar coeficientes de regresión o entrenar un modelo de machine learning con grandes volúmenes de datos históricos.
4. **Transparencia y explicabilidad regulatoria.** En el sector financiero, las decisiones de crédito suelen requerir justificación ante el cliente y ante reguladores. Un FIS basado en reglas lingüísticas es inherentemente más explicable (“se le asignó riesgo alto porque su historial de pago es regular y su ingreso relativo es bajo”) que un modelo de caja negra (por ejemplo, una red neuronal profunda), lo cual lo hace atractivo como capa de decisión interpretable.

4. Modelo Sugerido: Mamdani vs. Sugeno

Recomendación: Mamdani

Justificación:

- **Naturaleza evaluativa de la salida.** El “score de riesgo” es un juicio compuesto, análogo a una calificación cualitativa expresada numéricamente. Los modelos Mamdani son más adecuados cuando la salida representa una *evaluación experta* (Muy Bajo, Bajo, Moderado, Alto, Muy Alto) en lugar de una función matemática explícita de las entradas.
- **Interpretabilidad ante stakeholders no técnicos.** En un contexto financiero, poder mostrar “el score de riesgo es Alto porque el ingreso es Bajo y el historial es Regular” (lenguaje de las reglas Mamdani) es más útil para comunicación con comités de crédito o auditores que los coeficientes de una función Sugeno de tipo polinomial.
- **Diseño basado en conocimiento experto, no en datos masivos.** Este ejercicio parte de reglas que el profesor y los estudiantes definen con base en criterio experto (similar a cómo un analista de crédito razona), no de un proceso de ajuste automático sobre un histórico extenso de créditos otorgados. Mamdani es el enfoque natural cuando el FIS se construye “a mano”.

Cuándo se preferiría Sugeno en su lugar: si la institución contara con un histórico extenso de créditos (miles de casos con resultado conocido: pagó / no pagó) y se quisiera **entrenar automáticamente** el FIS con ANFIS para optimizar la predicción de incumplimiento, Sugeno sería la opción natural por su eficiencia computacional y compatibilidad con el aprendizaje supervisado. Para este ejercicio didáctico, basado en reglas expertas explícitas, Mamdani es la recomendación.

5. Estructura Sugerida del FIS

Entradas:

Ingreso relativo a deuda [0, 10]

- Insuficiente (trapmf)
- Bajo (trimf)
- Adecuado (trimf)
- Alto (trapmf)

Historial de pago [0, 10]

- Malo (trapmf)
- Regular (trimf)
- Bueno (trimf)
- Excelente (trapmf)

Salida:

Score de riesgo crediticio [0, 100]

- Muy Bajo (trimf)
- Bajo (trimf)
- Moderado (trimf)
- Alto (trimf)
- Muy Alto (trapmf)

Ejemplos de reglas:

SI Ingreso es Alto Y Historial es Excelente ENTONCES Riesgo es Muy Bajo
SI Ingreso es Adecuado Y Historial es Bueno ENTONCES Riesgo es Bajo
SI Ingreso es Bajo Y Historial es Regular ENTONCES Riesgo es Moderado
SI Ingreso es Insuficiente Y Historial es Malo ENTONCES Riesgo es Muy Alto
SI Ingreso es Alto Y Historial es Malo ENTONCES Riesgo es Alto
SI Ingreso es Insuficiente Y Historial es Excelente ENTONCES Riesgo es Moderado

Nota pedagógica: las dos últimas reglas son las más interesantes para discusión en clase, ya que ilustran cómo el historial de pago puede pesar más que el ingreso actual (asimetría de criterios), un matiz que un modelo lineal simple no captura.

6. Datos Sintéticos

El script `generar_datos_credito.m` genera un conjunto de datos sintéticos (ingreso relativo, historial de pago, score de riesgo) siguiendo una función experta no-lineal en la que el historial de pago tiene mayor peso relativo que el ingreso (asimetría intencional), más ruido gaussiano para simular variabilidad real entre solicitantes. Los datos se exportan en formato `.csv` y `.mat`, con partición train/test (80/20).